Estimación de la probabilidad condicional de ganar un punto en tenis profesional

Federico Soler

***Resumen*—Analizar un encuentro competitivo permite examinar cómo las decisiones de los jugadores modifican su desarrollo. En ajedrez, plataformas como *Chess.com* facilitan este análisis mediante una barra que representa la ventaja posicional estimada por un motor y se actualiza después de cada movimiento. Este trabajo explora si ese principio de evaluación secuencial puede trasladarse al tenis profesional, utilizando la probabilidad condicional de ganar el punto como medida del balance entre ambos jugadores después de cada tiro.**

Para ello, se entrena un ensamble supervisado de *XGBoost* sobre registros del *Match Charting Project*, utilizando características dinámicas del intercambio y una ventana temporal del tiro actual y los dos anteriores $(t, t-1, t-2)$. El modelo alcanzó un desempeño comparable al de investigaciones previas, con un Accuracy del 60.51 %, un AUC-ROC de 0.6410, un *Brier Score* de 0.2292, un *Expected Calibration Error* de 0.48 % y F_1-scores de 68.83 % para el sacador y 46.15 % para el restador. Los resultados confirman que las secuencias recientes de golpes contienen señal suficiente para rastrear, tras cada tiro, la evolución de la ventaja del sacador sin recurrir al ranking, al marcador ni a la identidad de los jugadores.

I. Introducción

En el ajedrez, el análisis de partidas se apoya ampliamente en la barra de evaluación ofrecida por plataformas como *Chess.com* [1], [2], la cual se ajusta dinámicamente tras cada jugada para reflejar qué bando tiene la iniciativa. Calculada mediante motores como *Stockfish* [3], [4], esta herramienta permite comprender de forma inmediata el impacto de cada decisión sobre las perspectivas del juego [5]. Desarrollar una métrica similar en el tenis profesional plantea el desafío de modelar el peloteo no como un resultado cerrado, sino como una secuencia de golpes donde cada tiro modifica la probabilidad condicional de ganar el punto.

En transmisiones televisivas de tenis, predominan tradicionalmente las estadísticas acumuladas (aces, primeros saques, tiros ganadores y errores no forzados). Si bien estas cifras describen el volumen global del juego, resultan insuficientes para comprender el desarrollo táctico del intercambio. Formalmente cada punto vale lo mismo según las reglas [6], pero la ventaja se construye y disputa impacto tras impacto. En este sentido, la literatura fundamenta la importancia del modelado tiro a tiro [7] para dimensionar objetivamente el peso de cada decisión en el peloteo.

En el ámbito del tenis, la literatura científica ha transitado desde el análisis notacional tradicional [8] y las taxonomías de golpes [9] hacia marcos analíticos orientados a medir el balance del juego. Diversos estudios formalizaron índices de ventaja posicional y coordinación interpersonal [10], [11], examinaron la dinámica espaciotemporal del peloteo [12] y modelaron fluctuaciones de *momentum* [13]. En el plano probabilístico, los antecedentes abarcan formulaciones estocásticas [14], minería de patrones tácticos [15] y algoritmos de aprendizaje automático para pronóstico de partidos [16], [17], [18], [19]. Frente a estas limitaciones, surgió el *Match Charting Project* (MCP) [20] como un repositorio público con registros estructurados golpe por golpe.

Por su parte, el ajedrez computacional resolvió tempranamente la evaluación de posiciones intermedias combinando algoritmos de búsqueda con poda alfa-beta [21] y, más recientemente, funciones de evaluación neurales eficientemente actualizables (NNUE) [22], [23], [24], capaces de detectar quiebres decisivos de ventaja incluso en secuencias tácticas breves [25]. Para trasladar una capacidad análoga a la naturaleza tabular y heterogénea del MCP, la literatura metodológica demuestra que los árboles de decisión CART [26] y los ensambles de gradiente potenciado (*boosting*) [27] han mostrado resultados competitivos frente a arquitecturas neuronales profundas en diversas tareas con datos tabulares [28] lo cual fundamenta la elección de algoritmos como *XGBoost* [29]. Para auditar rigurosamente estos modelos sin incurrir en fugas de información [30], la literatura describe métricas de discriminación (AUC-ROC [31], [32]) y técnicas de calibración probabilística (ECE [33], Brier Score [34]), cuya formulación matemática descansa en conceptos fundamentales de reconocimiento de patrones y aprendizaje automático [35].

Este trabajo propone estimar tiro a tiro la probabilidad condicional de que el jugador al servicio termine ganando el punto a partir de las características observables del intercambio en una ventana temporal tripartita $(t, t-1, t-2)$, prescindiendo deliberadamente de la identidad de los jugadores, de sus rankings, del marcador del partido, del torneo y de la superficie. La utilidad práctica de este modelado se ilustra analizando un punto de la final del US Open 2009 entre Roger Federer y Juan Martín del Potro, examinando cómo evoluciona la probabilidad del tanto a lo largo de un intercambio real.

El artículo se organiza de modo que la Sección II aborda el marco teórico, la Sección III detalla la ingeniería de características y el entrenamiento del modelo, la Sección IV expone los resultados y el caso de estudio, y la Sección V presenta la conclusión.

II. Marco teórico y antecedentes

II-A. Evaluación táctica en ajedrez

Este trabajo propone cuantificar decisiones para poder encontrar puntos en el desarrollo del juego que ayuden a explicar el desenlace final, pero no intenta trasladar directamente al tenis el funcionamiento de un motor como *Stockfish* [3]. En *Chess.com* [1], la métrica calculada representa la evaluación



Figura 1. Mate del Loco: (1) Posición inicial. (2) Apertura imprecisa *1. f3*. (3) Respuesta clásica *1... e5*. (4) Error crítico o *blunder* (*2. g4??*) que desploma la barra de evaluación indicando una desventaja decisiva. (5) Jaque mate (*2... Qh4#*). Fuente: capturas de la interfaz de *Chess.com*.

de la posición producida por el motor, pero su valor escalar no representa directamente una probabilidad de victoria [2]. Dicha métrica se proyecta visualmente como una barra vertical en la interfaz de la plataforma, como ilustra la Figura 1 en el clásico "Mate del Loco" [25].

Originalmente, *Stockfish* utilizaba una función de evaluación clásica (*Handcrafted Evaluation*, HCE), implementada por sus desarrolladores a partir de conceptos estratégicos del ajedrez, como la movilidad de las piezas, la estructura de peones, la posibilidad de enroque y la seguridad del rey. En 2020, *Stockfish* incorporó una arquitectura neuronal denominada NNUE (*Efficiently Updatable Neural Network*) entrenada a partir de grandes conjuntos de posiciones acompañadas de etiquetas con sus evaluaciones numéricas. La red aprendió a aproximar estas evaluaciones a partir de las configuraciones del tablero y reemplazó a la función de evaluación clásica [22], [23], [24]. Luego genera continuaciones posibles a partir de la posición actual para determinar su valor como el valor de la posición que resulta de la mejor secuencia de jugadas si ambos jugadores intentan jugar óptimamente, es decir, eligiendo en cada turno la posición de mayor valor [21]. El resultado es un puntaje escalar que permite comparar posiciones sucesivas, aunque no represente directamente puntos porcentuales de probabilidad de victoria [4], [5]. La posibilidad de explorar continuaciones constituye una diferencia fundamental entre el ajedrez y los datos disponibles para este trabajo. En ajedrez, una posición describe completamente el estado relevante del tablero, las reglas determinan el conjunto finito de movimientos legales y, para cada movimiento, el estado sucesor queda determinado de forma exacta. Mover un alfil a un cierto casillero desde una posición actual termina inequívocamente en una única posición siguiente. La notación no incluye más de una posición bajo el mismo nombre.

La representación proporcionada por el *Match Charting Project* (MCP) [20] no posee esta propiedad. Por ejemplo, puede registrar que un jugador ejecutó una derecha cruzada profunda, pero no especifica con precisión continua la posición de ambos jugadores ni la velocidad, altura y pique exactos de la pelota. Golpear una derecha cruzada profunda no termina inequívocamente en un único estado posible dado que si hubiese botado 5 cm más lejos o a 3 km/h más rápido se hubiese llamado derecha cruzada profunda de igual manera. En consecuencia, a partir de un estado codificado en el MCP no es posible determinar de forma determinista cuál sería el estado producido por cada posible respuesta del rival dado que en el tenis el espacio de acciones es esencialmente continuo, tanto la ejecución física de un golpe como su resultado efectivo conllevan incertidumbre. Incluso disponiendo de información cinemática de seguimiento óptico de alta precisión como la provista por *Hawk-Eye* [11], sería necesario modelar probabilísticamente las transiciones entre estados antes de poder proyectar ramas futuras de forma análoga a un motor de ajedrez.

La evaluación propuesta se refiere al desenlace de un punto individual, unidad de puntuación que se integra posteriormente en juegos y sets según las reglas del tenis [6].

Por estas razones, el presente trabajo traslada al tenis el principio de asignar una evaluación escalar a cada estado del peloteo, pero descarta el mecanismo de búsqueda generativa y evaluación de *Stockfish*. Se propone entonces la función de evaluación del estado como la probabilidad condicional estimada de que el jugador al servicio gane el punto:

$$V(S_t) = P(Y = 1 \mid S_t), \tag{1}$$

donde $Y = 1$ representa la victoria del sacador y S_t sintetiza el estado táctico observable acumulado hasta el tiro t. Aunque ambas métricas permitan evaluar las decisiones de juego tras cada acción, las magnitudes representadas no son equivalentes.

II-B. Evaluación táctica en tenis

Para abordar el paradigma de la valoración tiro a tiro en el tenis, Floyd et al. [14], [7] formularon el *Expected Shot Win Rate* (ESWR) a partir de modelos de valor de posesión del baloncesto, posteriormente adaptado al tenis por Emery y Freeman [12] bajo el concepto de *Expected Shot Value* (ESV). Este enfoque se diferencia de los antecedentes de análisis notacional y clasificación de golpes, que describen las acciones observadas sin asignar necesariamente una probabilidad de victoria a cada estado del intercambio [8], [9].

Dividen la cancha en 30 zonas fijas y le asignan puntajes preestablecidos a lo que pasa después de cada tiro: 1.0 si fue tiro ganador, 0.5 si fue un peloteo neutro y 0.0 si terminó en error. Con eso y con la identidad de los jugadores para armar matrices de transición, calculan tras cada golpe un valor esperado para el que pega y otro para el que responde.

Por otro lado, Carvalho et al. [10] formalizaron el Índice de Ventaja Posicional (*Positional Advantage Index*, PA Index), evaluado luego por van Meurs y Bu [11] sobre datos de *Hawk-Eye*. En el instante en que la raqueta impacta la pelota, mide la posición de ambos jugadores calculando qué tan lejos están de la red y de la línea central penalizando alejarse del centro.

El resultado se actualiza en cada impacto y da un número en metros cuadrados que si es negativo, significa que el jugador que golpeó está mejor ubicado en la cancha que su rival, si es positivo, está en desventaja espacial, y si ronda el cero, hay paridad geométrica.

Otros trabajos han estudiado los patrones tácticos y las fluctuaciones de ventaja durante los intercambios, ampliando las formas de describir su evolución [15], [13].

Ni el PA Index ni el ESWR o ESV constituyen una probabilidad de ganar el punto ni fueron obtenidos a partir de un modelo de aprendizaje supervisado, pero representan a su manera la ventaja de un jugador sobre el otro durante un punto. El modelo propuesto por este trabajo entrena un ensamble de árboles de decisión (*XGBoost* [29]) contra la etiqueta binaria del desenlace terminal del punto ($Y \in \{0, 1\}$) a partir de datos del *Match Charting Project* (MCP) [20], prescindiendo de datos estáticos como la identidad de los jugadores y el marcador para evitar que la predicción dependa de información ajena a la secuencia dinámica de golpes, una precaución coherente con la literatura sobre fugas de información [30]. De este modo, la salida del modelo estima directamente la probabilidad de victoria condicionada a las características del intercambio como el tipo de golpe, dirección y profundidad de los tres golpes más recientes.

Los antecedentes de predicción de resultados de tenis también incluyen enfoques que trabajan a nivel de partido, una escala distinta de la evaluación de cada golpe propuesta aquí [16], [17].

Por su parte, Illum et al. [19] utilizaron tanto el MCP, restringido a registros entre 2016 y 2020 sobre Wimbledon y el US Open, como *XGBoost* para predecir la probabilidad condicional de ganar el punto, pero su análisis se limita al nivel de punto completo, es decir, una sola fila en su tabla por cada punto jugado en lugar de por cada golpe. Según el análisis de ganancia, las variables más influyentes fueron los sets ganados, los puntos de quiebre del restador y el ranking de los jugadores, mientras que las de colocación del saque y la devolución aportaron muy poco. Los autores cuestionaron el desempeño del modelo, dado que iguala o empeora al baseline y su capacidad discriminativa es apenas superior al azar. Concluyen que los datos públicos disponibles no son adecuados para ese fin.

Este trabajo se sitúa entonces en la intersección de las dos líneas de investigación expuestas en esta sección. Por un lado, las métricas que evalúan golpes con granularidad tiro a tiro no pueden ser interpretadas directamente como la probabilidad de ganar el punto ni emplean XGBoost sobre el MCP. Por otro, el trabajo que sí utiliza XGBoost sobre el MCP presenta una granularidad punto a punto y un desempeño predictivo reducido que pudo haberse debido a conservar variables estáticas como el ranking y el marcador, que aquí se filtraron deliberadamente al observar que tendían a encabezar sistemáticamente las tablas de importancia de características (*feature importance*) durante las primeras versiones del prototipo.

II-C. Elección del modelo

Para modelar la dinámica del intercambio a partir de los registros tabulares del MCP, los ensambles de árboles, y en particular *XGBoost* [29], constituyen una alternativa competitiva según la literatura consultada [27], [28]. En diversas tareas tabulares heterogéneas, los ensambles de árboles han mostrado un rendimiento competitivo frente a redes neuronales profundas [28], [18].

Un árbol individual [26] corta al conjunto de datos en subgrupos cada vez más homogéneos en cuanto a su etiqueta. Dado que el conjunto de datos que eventualmente le pasemos tendrá únicamente variables binarias (One-Hot) donde el valor siempre es 1 o 0, los puntos de corte son simplemente uno por feature lo cual equivale a preguntas como ¿Hubo subida a la red en este tiro?, ¿Sí o no?, ¿La pelota previa del rival fue corta?, ¿Sí o no?. Luego repite el acto de subdividir hasta llegar a un criterio de corte que, si bien no suele dejar perfectamente homogéneos a los subgrupos de las hojas finales, consolida un conjunto de preguntas para hacerle a un nuevo golpe a futuro cuando no se disponga de su etiqueta. Según sus respuestas, lo ubicaría en alguno de los nodos hoja para asignarle la etiqueta predominante de ese subgrupo.

El principio de potenciación por gradiente (*Gradient Boosting*) [27] construye una secuencia de árboles que colaboran entre sí. El primer árbol realiza una aproximación inicial básica, el segundo árbol se entrena para corregir el error del primero, el tercero el del segundo, y así sucesivamente logrando que la combinación ponderada de todas las correcciones transforme un conjunto de reglas rígidas en una estimación más refinada.

La arquitectura *XGBoost* (*Extreme Gradient Boosting*) es una implementación optimizada del *boosting* tradicional [29]. Calcula con precisión hacia dónde corregir el error, poda automáticamente ramas innecesarias, y atenúa la influencia de cada árbol sucesivo para combatir el sobreajuste. Al transformar las características de cada tiro mediante One-Hot encoding, cada fila de la tabla pasa a contener una enorme cantidad de ceros, en esencia una matriz dispersa. El algoritmo busca únicamente las filas donde efectivamente aparece un uno y, para el resto de las observaciones, aprende una dirección por defecto y envía todos esos ceros juntos en un solo bloque hacia la otra rama. En la práctica, esta arquitectura es la que permite entrenar sobre los millones de impactos presentes en el MCP con un costo computacional manejable, y que al momento de evaluar un tiro nuevo solo tenga que verificar unos pocos valores activos, calculando la probabilidad de victoria en una fracción de milisegundo.

Los ejemplos nuevos para los que se busca obtener una probabilidad ingresan al modelo como un vector de variables binarias al nodo raíz del primer árbol del ensamble. Durante el entrenamiento, *XGBoost* encuentra que dividir las observaciones según una cierta variable ofrece una reducción favorable de la función de pérdida (*gain*), comparada con otras divisiones en variables candidatas. Después de dividir la cantidad de veces correspondiente a la profundidad elegida como hiperparámetro para el modelo, el ejemplo llega finalmente a un nodo hoja determinado que contiene un peso aprendido durante el entrenamiento, denominado *leaf weight* y significa que el primer árbol reduce en esa cantidad el margen logit de la predicción.

La escala logit [35] es una forma alternativa de expresar una

probabilidad, utilizando números que pueden ir desde menos infinito hasta más infinito. Una probabilidad está limitada al intervalo entre 0 y 1. En cambio, el logit se calcula mediante $z = \ln(p/(1-p))$. Un logit de 0 equivale a una probabilidad del $50\,\%$. Los valores positivos representan probabilidades superiores al $50\,\%$ y los negativos, inferiores. Si cada árbol devolviera directamente una etiqueta binaria ($Y = 0$ o $Y = 1$), se requeriría otro mecanismo para combinar esas 200 decisiones, como una votación. En cambio, XGBoost combina las contribuciones numéricas de los árboles sobre una misma escala logit.

Para comenzar esta suma, el modelo necesita un valor inicial denominado sesgo base (*prior*), que representa la predicción antes de que intervenga cualquiera de los 200 árboles. En una configuración de aprendizaje automático, este valor puede estimarse a partir de las etiquetas de entrenamiento; su valor efectivo depende de la versión y configuración del modelo. *XGBoost* utiliza el parámetro `base_score` como predicción inicial, que luego se proyecta a escala logit para poder sumarle el peso del nodo hoja del primer árbol, y se avanza sucesivamente a través de los demás árboles del ensamble.

Una vez sumadas las contribuciones de todos los árboles al sesgo base, el resultado todavía se encuentra en escala logit y no puede interpretarse directamente como una probabilidad. Para convertirlo en la probabilidad de que $Y = 1$, se utiliza [35] la función sigmoide: $p = 1/(1+e^{-z})$, donde z representa el margen logit final obtenido por el ensamble.

II-D. Métricas de evaluación

Accuracy calcula la proporción de aciertos del modelo, tanto verdaderos positivos (VP) como verdaderos negativos (VN). Por ejemplo, si el modelo realiza 100 predicciones y acierta 60, obtiene un Accuracy del 60 %. Pero, es importante recalcar que cada predicción correcta cuenta como un acierto completo, independientemente de la probabilidad que el modelo haya asignado al resultado. Consideremos dos modelos que predicen que el sacador ganará un punto. El primero estima una probabilidad del 51 % y el segundo una probabilidad del 95 %. Si el sacador efectivamente gana, ambos modelos reciben exactamente el mismo reconocimiento por parte de Accuracy aunque sus estimaciones probabilísticas sean muy diferentes.

Precision mide qué proporción de las victorias predichas del sacador ($\hat{Y} = 1$) corresponde a victorias reales ($Y = 1$), mientras que *Recall* mide qué proporción de las victorias reales del sacador ($Y = 1$) fue correctamente identificada ($\hat{Y} = 1$). Por ejemplo, dos modelos podrían alcanzar exactamente el mismo Accuracy, pero uno acertar principalmente los puntos ganados por el sacador y el otro distribuir sus aciertos de manera más equilibrada entre ambas clases. En ese caso, Precision y Recall permitirían detectar una diferencia que Accuracy oculta.

El *F1-score* varía entre 0 y 1. Por ejemplo, si el modelo tiene Precision de 80 % y Recall de 40 %, su F1-score es 0,533 (53,3 %), un resultado modesto. Aunque sus predicciones positivas suelen ser correctas, está dejando sin detectar muchos puntos ganados por el restador. Por lo tanto, Accuracy, Precision, Recall y F1-score pierden información probabilística que es esencial para un modelo de las características propuestas en este trabajo.

Dado que las métricas previamente mencionadas trabajan colapsando la probabilidad asignada según un umbral arbitrario ($p > 0{,}5$ *vs.* $p \leq 0{,}5$) para determinar aciertos y errores, se incluye el *Brier Score* que relaciona la etiqueta final (Y) directamente con la probabilidad asignada por el modelo (p) [34]. Por ejemplo, si el modelo predice un 80 % (0,80) y el sacador termina ganando el punto (1), el error puntual de ese tiro es muy bajo, $(0{,}80 - 1)^2 = 0{,}04$. En cambio, si pierde el punto (0), el error castiga severamente la sobreconfianza injustificada, $(0{,}80 - 0)^2 = 0{,}64$. Al promediar estos errores sobre cientos de miles de tiros, se obtiene un indicador global donde un puntaje más bajo refleja predicciones más exactas.

La métrica *ROC-AUC* [31], [32] sirve para medir la probabilidad de que el modelo asigne una puntuación mayor a la observación correspondiente a una victoria del sacador (Y=1) que a la correspondiente a una derrota (Y=0). Por ejemplo, un ROC-AUC de **0,65** significa que, si se elige aleatoriamente un golpe perteneciente a un punto ganado por el sacador y otro perteneciente a un punto perdido, el modelo le asignará una probabilidad mayor al primero aproximadamente el 65 % de las veces. No evalúa si esas probabilidades son numéricamente correctas. Evalúa si el modelo consigue distinguir las observaciones de ambas clases asignándoles valores relativamente mayores o menores.

El *Expected Calibration Error* (ECE) [33] se incluye para responder la siguiente pregunta: Cuando el modelo devuelve una probabilidad de 70 %, ¿el sacador realmente gana el 70 % de las veces?. Para calcularlo, se particiona el espacio de predicciones en 10 intervalos (0–10 %, 10–20 %, …, 90–100 %) y calcula la diferencia entre la confianza promedio prometida y los triunfos reales en cada grupo. De este modo, el ECE cuantifica la desviación porcentual promedio entre lo que el modelo promete y lo que ocurre en la cancha.

III. Componentes y metodología

III-A. Ingeniería de características

Del corpus completo del MCP se descartaron los encuentros del circuito femenino (WTA) para centrar el análisis exclusivamente en partidos entre jugadores diestros del circuito profesional masculino (ATP) con el objetivo de filtrar posibles patrones tácticos presentes en uno de los circuitos pero no en el otro y evitar diferencias tácticas por lateralidad. Se depuraron también jugadas atípicas (como desvíos fortuitos por contacto con la faja de la red) y registros truncos carentes de secuencia válida de intercambio.

Durante las primeras versiones del prototipo se observó que variables estáticas ajenas al peloteo como el ranking, la identidad de los jugadores, la superficie, el torneo y el marcador encabezaban sistemáticamente los gráficos de análisis de feature importance, aportando información predictiva sin describir las acciones ejecutadas durante el intercambio. Se entiende por variable estática aquella cuyo valor permanece constante durante los sucesivos tiros de un punto, aunque pueda cambiar entre puntos o partidos. Su predominio motivó la decisión de excluir deliberadamente estas variables para

Cuadro I
CONJUNTO DE 58 FEATURES DEL MODELO PROPUESTO

#	Grupo de Variables (*Features*)	Descripción Conceptual y Codificación Notacional	Columnas One-Hot
1	`sacador_al_tiro`	Rol del ejecutor en el impacto ($1 =$ sacador, $0 =$ restador).	1
2	`profundidad_corta/media/profunda`	Profundidad del tiro actual (t): corta, media y profunda.	3
3	`prev_profundidad_corta/media/profunda`	Profundidad del tiro previo del oponente ($t-1$).	3
4	`anteprev_profundidad_corta/media/profunda`	Profundidad del tiro anterior del propio jugador ($t-2$).	3
5	`subida_a_red`	Indicador de aproximación a la red en el tiro actual (t).	1
6	`prev_subida_a_red`	Indicador de aproximación a la red del rival en el golpe previo ($t-1$).	1
7	`anteprev_subida_a_red`	Indicador de aproximación a la red del propio jugador en su golpe anterior ($t-2$).	1
8	`golpe_*`	Tipología del tiro actual (t): derecha, revés, slice (derecha y revés), voleas, smashes, saques (abierto, cuerpo, T) y marca base (`ninguno`).	11
9	`prev_golpe_*`	Tipología del tiro previo del oponente ($t-1$): golpes reales e indicador de inicio (`ninguno`).	11
10	`anteprev_golpe_*`	Tipología del tiro anterior del propio jugador ($t-2$): golpes reales e indicador de inicio (`ninguno`).	11
11	`direccion_*`	Dirección del tiro actual (t): paralelo, centro, cruzado o indefinida/saque.	4
12	`prev_direccion_*`	Dirección del tiro previo del oponente ($t-1$).	4
13	`anteprev_direccion_*`	Dirección del tiro anterior del propio jugador ($t-2$).	4
		Total de Variables Predictoras Oficiales	**58**

concentrar el aprendizaje en características dinámicas del peloteo, como el tipo de golpe, su dirección y profundidad.

La identidad de los jugadores también fue excluida para evitar que el modelo utilizara su historial competitivo como atajo predictivo. Por ejemplo, reconocer a Federer, Nadal o Djokovic podría llevarlo a asignar probabilidades favorables basándose en sus resultados históricos, sin distinguir suficientemente las características del golpe ejecutado. Además, al no depender de identidades conocidas durante el entrenamiento, la representación puede aplicarse a jugadores que ingresen posteriormente al circuito sin requerir nuevas variables para identificarlos.

La representación final se estructura en 58 variables binarias (*One-Hot*) formalizadas en el Cuadro I, que describen el rol del golpeador, el tipo de golpe, la dirección, y la profundidad a través de una ventana tripartita, compuesta por el tiro actual (t), la respuesta previa del adversario ($t-1$) y el impacto preparatorio propio ($t-2$). La variable `sacador_al_tiro` conmuta en cada impacto (1 para el sacador, 0 para el restador) y es necesaria para determinar si una pelota en t incrementa o disminuye la probabilidad condicional estimada del sacador.

III-B. Entrenamiento del modelo

El proceso se desarrolló íntegramente en el ecosistema científico de *Python* (*NumPy*, *Pandas* y *Scikit-Learn*) empleando la librería *XGBoost* 2.0 configurada con función de pérdida logística binaria (`binary:logistic`) para el entrenamiento supervisado.

Para evitar que los tiros de un mismo partido aparezcan tanto en entrenamiento como en prueba y permitir reproducir la partición (`random_state=42`), los 4.848 partidos se dividieron rígidamente mediante *GroupShuffleSplit* (80/20) agrupado por identificador de partido (`match_id`), con 3.878 partidos (2.952.453 tiros) para entrenamiento y 970 partidos (711.993 tiros) para prueba, verificando que el encuentro seleccionado como caso de estudio quedara íntegramente en este último conjunto. La partición agrupada por `match_id` impide que tiros pertenecientes a un mismo encuentro se distribuyan entre entrenamiento y prueba, eliminando una posible fuga de información.

La elección de hiperparámetros fue el resultado de una evolución a lo largo de las versiones del proyecto, desde las pruebas iniciales hasta la arquitectura tripartita final:

1. Cantidad de árboles (`n_estimators = 200`): En pruebas con 350 árboles se observó que la función de pérdida alcanzaba una meseta a partir de los 180–200 árboles. Extender el ensamble aportaba una ganancia marginal inferior a $+0{,}05\,\%$ en AUC-ROC, duplicando el costo computacional.
2. Profundidad de cada árbol (`max_depth = 8`): En iteraciones previas se empleó `max_depth = 6` como punto de partida. Sin embargo, dado que cada bifurcación formula una única pregunta de decisión binaria sobre una variable específica (por ejemplo, si existió un revés en $t-1$), una profundidad inferior a 8 no disponía de los niveles secuenciales necesarios para capturar la interacción de los tres turnos del intercambio. A su vez, al permitir profundidades de 10 o 12 niveles, los árboles tendían a memorizar ruido de las anotaciones del *MCP*, degradando el *Brier Score* y el *ECE*. Un límite de 8 niveles ofreció el compromiso exacto entre capacidad de entrelazar interacciones no lineales de tres turnos de juego y preservación de la capacidad de generalización.
3. Tasa de aprendizaje (`learning_rate = 0.05`, $\eta = 0{,}05$, *shrinkage*): Con la tasa de aprendizaje por defecto (`0.1`), el ensamble convergía prematuramente a partir de los primeros estimadores y corregía los residuales de forma agresiva. Esto polarizaba las probabilidades hacia valores extremos (cercanos a $0{,}05$ o $0{,}95$ en jugadas disputadas), perjudicando la calibración requerida para una barra continua televisiva.
4. Submuestreo de características (`colsample_bytree = 0.80`): Al utilizar la totalidad de las características (`colsample_bytree = 1.0`), las variables dominantes del tenis (como la dirección del saque o los impactos ganadores en la red) eran seleccionadas sistemáticamente en los nodos raíz de casi todos los árboles, generando estimadores altamente correlacionados entre sí y desatendiendo variables tácticas secundarias. Forzar a cada árbol a prescindir aleatoriamente de un $20\,\%$

Cuadro II
MATRIZ DE CONFUSIÓN SOBRE EL CONJUNTO DE PRUEBA

	Predicción del Modelo ($\hat{Y}$)		
Clase Real (Y)	**Restador ($\hat{Y}=0$, Negativo)**	**Sacador ($\hat{Y}=1$, Positivo)**	**Total Observado**
Restador ($Y=0$, Negativo)	**120.455** (16.92 %) **Verdadero Negativo (VN / Negativo correcto)** *Restador gana y el modelo predice restador*	187.850 (26.38 %) **Falso Positivo (FP / Error Tipo I)** *Restador gana pero el modelo predice sacador*	308.305 (43.30 %)
Sacador ($Y=1$, Positivo)	93.297 (13.10 %) **Falso Negativo (FN / Error Tipo II)** *Sacador gana pero el modelo predice restador*	**310.391** (43.60 %) **Verdadero Positivo (VP / Positivo correcto)** *Sacador gana y el modelo predice sacador*	403.688 (56.70 %)
Total Asignado	213.752 (30.02 %)	498.241 (69.98 %)	**711.993** (100.0 %)

Cuadro III
ESTUDIO DE ABLACIÓN TEMPORAL DEL ENSAMBLE SUPERVISADO FRENTE A LÍNEAS BASE DUMMY

Modelo	**Accuracy**	**AUC-ROC**	**Brier Score**	**ECE**	**Sacador (Clase 1)**			**Restador (Clase 0)**		
					Prec.	**Rec.**	F_1	**Prec.**	**Rec.**	F_1
Dummy ($p=0{,}50$)	50.00 %	50.00 %	0.2500	6.70 %	56.70 %	50.00 %	53.14 %	43.30 %	50.00 %	46.41 %
Dummy ($p=0{,}567$)	56.70 %	50.00 %	0.2455	0.16 %	56.70 %	100.00 %	72.37 %	0.00 %	0.00 %	0.00 %
XGBoost (t)	59.40 %	61.04 %	0.2364	0.14 %	61.42 %	76.33 %	68.07 %	54.57 %	37.23 %	44.27 %
XGBoost ($t, t-1$)	60.34 %	63.77 %	0.2302	0.39 %	62.25 %	76.34 %	68.58 %	55.98 %	39.39 %	46.24 %
XGBoost ($t, t-1, t-2$)	**60.51 %**	**64.10 %**	**0.2292**	**0.48 %**	**62.30 %**	**76.89 %**	**68.83 %**	**56.35 %**	**39.07 %**	**46.15 %**

de las columnas obligó al algoritmo a explorar variables alternativas pero decisivas (como la profundidad del pique rival en $t-1$ o la preparación espacial en $t-2$), descorrelacionando los árboles y enriqueciendo la diversidad del ensamble.

5. Submuestreo de instancias (`subsample = 0.90`): Reducciones más agresivas del conjunto de entrenamiento (`subsample = 0.60` a `0.80`) provocaban que jugadas de baja frecuencia muestral (como *drop-shots*) perdieran soporte estadístico en los árboles individuales. Entrenar cada árbol con el $90\,\%$ aleatorio de los tiros introdujo la estocasticidad necesaria para preservar la representatividad de los impactos poco frecuentes.
6. Cuantización por histogramas (`tree_method = 'hist'`): El algoritmo de corte tradicional (`tree_method = 'exact'`) calculaba divisiones continuas sobre casi tres millones de filas, requiriendo varias horas de cómputo y una demanda excesiva de memoria. La cuantización por histogramas consciente de la dispersión de ceros (*sparsity-aware*) aprovechó la estructura One-Hot dispersa de la matriz, reduciendo el tiempo total de entrenamiento de los tres modelos de ablación a menos de dos minutos con idéntica precisión predictiva. A su vez, la inferencia del ensamble, una vez disponibles las 58 covariables de entrada, presenta una latencia inferior a 0.1 ms por tiro, por lo que el modelo predictivo en sí no constituye un cuello de botella para una eventual implementación durante transmisiones televisivas.

IV. RESULTADOS

IV-A. Evaluación del modelo

El Cuadro III muestra el desempeño predictivo del ensamble propuesto frente a dos *modelos dummy* y a las sucesivas ventanas de memoria temporal sobre el conjunto de prueba.

Un *modelo dummy* es un clasificador de referencia que prescinde por completo de los features de entrada, es decir, no realiza ningún cálculo interno y su respuesta es fija. En este trabajo se evalúan dos variantes. **Dummy Uniforme** ignora la ventaja asociada al servicio representando el azar (50/50) y obtiene un Accuracy mecánico del $50{,}00\,\%$. Obtiene un ECE de $6{,}70\,\%$, indicando un desfasaje del $6{,}7\,\%$ entre su predicción del $50\,\%$ y la frecuencia real del $56{,}7\,\%$. **Dummy Mayoría** refleja la probabilidad histórica del conjunto de entrenamiento, donde el sacador gana el $56{,}70\,\%$ de los puntos. Como predictor, siempre pronostica que gana el sacador y obtiene un Accuracy del $56{,}70\,\%$ pero también carece de capacidad discriminativa (AUC-ROC $= 50{,}00\,\%$). Obtiene un ECE muy cercano a cero de $0{,}16\,\%$ porque no arriesga nunca. Apuesta al promedio histórico global y, como en el test set el promedio también es $56{,}7\,\%$, su único intervalo coincide casi a la perfección con la realidad.

El modelo propuesto alcanzó un Accuracy global del **60.51 %**, un AUC-ROC de **0.6410** y un *Brier Score* de **0.2292**, confirmando una capacidad discriminativa por encima del azar. Asimismo, reduce el *Brier Score* a **0.2292**, respaldando que el ensamble asigna probabilidades calibradas sin incurrir en sobreconfianza. Complementariamente, el ECE fue de **0.48 %**, reflejando una estrecha correspondencia promedio entre las probabilidades estimadas y las frecuencias observadas en la cancha. A medida que el modelo se vuelve más inteligente, ya no predice siempre $56{,}7\,\%$. Se anima a predecir $20\,\%, 35\,\%, 72\,\%, 88\,\%$. Al dispersar predicciones en los 10 intervalos, cada grupo tiene pequeñas variaciones estadísticas naturales, lo que hace que el ECE suba levemente a $0{,}48\,\%$ en comparación con el ECE de Dummy Mayoría. El ECE obtenido (menor al medio punto porcentual) indica que si el modelo asigna a un golpe un $72\,\%$, en esa situación los sacadores ganan el $72\,\%$ de las veces.

La matriz de confusión (Cuadro II) respalda que el clasi-

ficador no se limita a predecir siempre al sacador, sino que identifica correctamente victorias del restador como Verdaderos Negativos (VN, logrando un $F_1 = 46{,}15\,\%$), y las victorias del sacador como Verdaderos Positivos. La suma de ambas celdas diagonales de acierto fundamenta el Accuracy global del **60.51 %**.

Finalmente, el estudio de ablación temporal (Cuadro III) demuestra que la respuesta inmediata del adversario ($t-1$) concentra el mayor salto predictivo (+2.73 % en AUC-ROC), mientras que el tiro preparatorio propio ($t-2$) aporta una ganancia complementaria menor (+0.33 % en AUC-ROC). Este comportamiento llevó a adoptar una ventana de segundo orden ($k = 2$) como un compromiso óptimo entre capacidad predictiva y dimensionalidad. En conjunto, estos resultados respaldan que el modelo no solo supera a los predictores triviales, sino que entrega probabilidades calibradas para seguir la evolución táctica del punto.

IV-B. Caso de estudio sobre la final del US Open 2009

Para ilustrar la interpretabilidad del modelo, se evaluó el primer punto del segundo game de la final del US Open 2009 (Del Potro al servicio frente a Federer), perteneciente al conjunto de prueba. La Figura 2 exhibe la evolución continua de las probabilidades condicionales de victoria estimadas tiro a tiro para ambos jugadores. Las probabilidades previas al peloteo corresponden a las tasas basales observadas en el dataset original ($64{,}30\,\%$ cuando el sacador juega con su primer saque y $50{,}96\,\%$ cuando juega con el segundo).

El cuarto tiro del punto corresponde a una derecha corta al centro ejecutada por el sacador Juan Martín del Potro. Para evaluarla, *XGBoost* recibe como entrada el vector de 58 características One-Hot que la describe. Al ingresar al primero de los 200 árboles, el tiro comienza en el nodo raíz, que pregunta si dos golpes atrás no existía un golpe registrado (`anteprev_golpe_ninguno`). En el tiro 4 vale 0, porque sí existe el golpe de dos posiciones anteriores en el peloteo continuo (el segundo servicio, tiro 2), por lo que el tiro continúa por la rama del árbol correspondiente al valor 0 hasta atravesar otros siete nodos y llegar al nodo hoja 234, que contiene un leaf weight de $-0{,}022680$. *XGBoost* suma ese peso al `base_score` de $= 0{,}56534654$, situando el margen tras este primer paso en $+0{,}240210$ ($55{,}97\,\%$ de probabilidad), y se avanza sucesivamente a través de los siguientes árboles.

Al atravesar los 200 árboles, la corrección conjunta de todos los estimadores asciende a $-0{,}055300$, alcanzando un logit final de $+0{,}207590$ que luego de pasar por la función sigmoide devuelve finalmente $\approx 0{,}5517$, es decir, un $55{,}17\,\%$ de probabilidad de victoria para el sacador. El cálculo detallado se resume en el Cuadro IV.

Cuadro IV
CÁLCULO DEL VALOR DEL TIRO 4 MEDIANTE XGBOOST

Árbol 1 (Hoja 234)		
Decisión	**Feature**	**Rama**
1	`anteprev_golpe_ninguno`	0
2	`subida_a_red`	0
3	`prev_subida_a_red`	0
4	`anteprev_subida_a_red`	0
5	`anteprev_profundidad_media`	0
6	`prev_profundidad_profunda`	1
7	`direccion_indefinida`	0
8	`direccion_centro`	1
Predicción del Ensamble		
Componente	**Expresión**	**Aporte**
Sesgo base	$b_0 = \ln(p_0/(1-p_0))$	$+0{,}262890$
Árbol 1	$f_1(x)$ (*leaf weight*)	$-0{,}022680$
200 árboles	$\sum_{m=1}^{200} f_m(\mathbf{x})$	$-0{,}055300$
Logit final	$z = b_0 + \sum_{m=1}^{200} f_m(\mathbf{x})$	$+0{,}207590$
Probabilidad final	$\sigma(z) = 1/(1+e^{-z})$	**55,17 %**

V. CONCLUSIÓN

Este trabajo traslada al tenis profesional el principio de evaluación secuencial utilizado en el ajedrez, definiendo una métrica que estima la probabilidad condicional de victoria del sacador tras cada golpe a partir de los features dinámicos del intercambio. La ventana tripartita contiene señal suficiente para rastrear las fluctuaciones de ventaja del punto con alta velocidad de cómputo. El principal aporte metodológico de este trabajo reside en la ingeniería de características propuesta, que combina el anonimato de los jugadores, la exclusión de variables contextuales estáticas y la ventana temporal tripartita (t, t$-$1, t$-$2).

No obstante, se cita como obstáculo que al carecer de variables cinemáticas continuas como la velocidad, la trayectoria o la posición de los jugadores, múltiples ejecuciones físicamente diferentes colapsan bajo una misma categoría notacional. En trabajos futuros, se podría pensar en incorporar datos de seguimiento óptico continuo para describir la cinemática tridimensional de la pelota y los competidores. Se sugiere también explorar ventanas completas que abarquen todos los golpes previos de la secuencia del punto más allá de la ventana tripartita propuesta.

REFERENCIAS

[1] Chess.com, "Herramienta de análisis algorítmico y revisión de partidas," https://www.chess.com/analysis, 2026, accedido en 2026.

[2] ——, "How does the evaluation bar work?" https://support.chess.com/en/articles/8593452-how-does-the-eval-bar-work, 2024, documentación oficial de soporte de Chess.com.

[3] Stockfish Development Team, "Stockfish: Open source chess engine," https://stockfishchess.org, 2026, accedido en 2026.

[4] ——, "Stockfish evaluation and the WDL (Win–Draw–Loss) model," https://github.com/official-stockfish/Stockfish/wiki/Stockfish-FAQ, 2024, documentación oficial de evaluación y probabilidades de Stockfish.

[5] K. W. Regan and G. M. Haworth, "Intrinsic chess ratings," in *Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence (AAAI-11)*, vol. 25, no. 1, 2011, pp. 834–839.

[6] United States Tennis Association, "Tennis terms: Words to know and rules of tennis," https://www.usta.com/en/home/improve/tips-and-instruction.html, 2023, glosario oficial de terminología y especificaciones reglamentarias de la USTA.

[7] C. M. Floyd, M. J. Hoffman, and E. Fokoue, "Shot-by-shot stochastic modeling of individual tennis points," *Journal of Quantitative Analysis in Sports*, vol. 16, no. 1, 2020.

[8] P. O'Donoghue and B. Ingram, "A notational analysis of elite tennis strategy," *Journal of Sports Sciences*, vol. 19, no. 2, pp. 107–115, 2001.

[9] S. Kovalchik and M. Reid, "A shot taxonomy in the era of tracking data in professional tennis," *Journal of Sports Sciences*, vol. 36, no. 18, pp. 2096–2104, 2018.

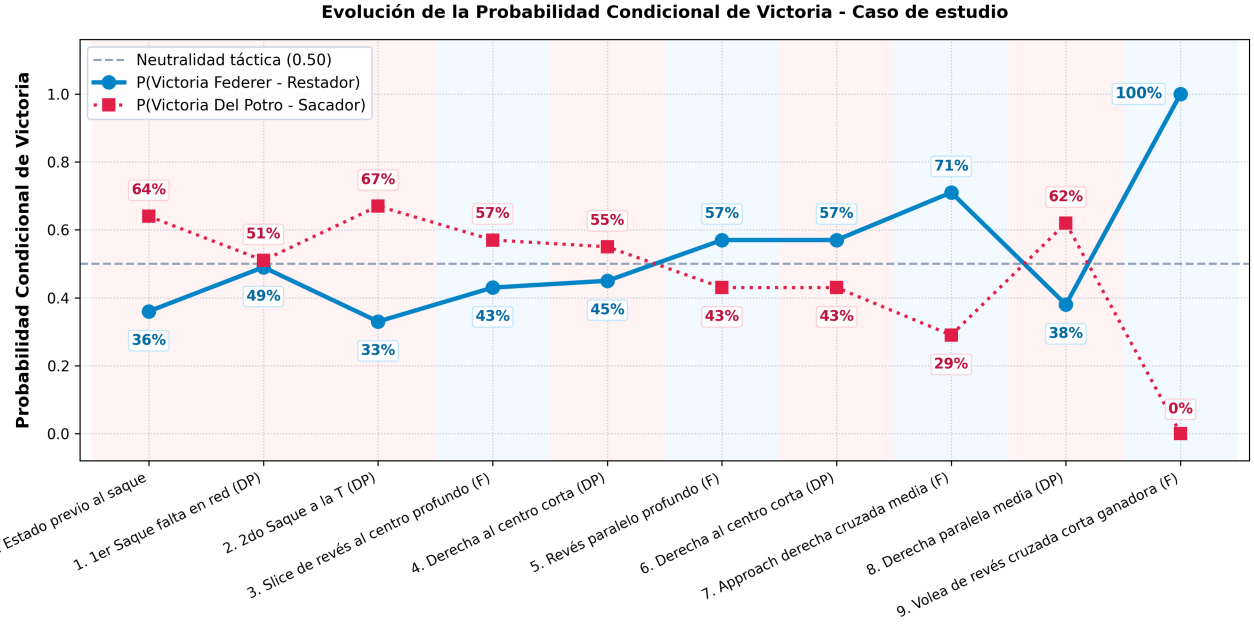


Figura 2. Evolución de la probabilidad condicional de victoria para el caso de estudio.

[10] J. Carvalho, D. Araújo, L. García-González, and D. Iglesias, "Elucidating interpersonal coordination in tennis: A spatiotemporal approach," *Human Movement Science*, vol. 32, no. 6, pp. 1265–1278, 2013.

[11] E. van Meurs, T. Buszard, S. Kovalchik, D. Farrow, and M. Reid, "Interpersonal coordination in tennis: assessing the positional advantage index with australian open hawkeye data," *International Journal of Performance Analysis in Sport*, vol. 21, no. 1, pp. 22–32, 2021.

[12] C. Emery and P. Freeman, "Augmenting tennis point stochastic modeling utilizing spatiotemporal shot data," Senior Honors Thesis, Carnegie Mellon University, 2020.

[13] C. Liu, J. Yang, and Y. Cui, "Quantifying and predicting momentum in tennis match via machine learning approach," *International Journal of Racket Sports Science*, vol. 7, no. 1, pp. 46–58, 2025.

[14] C. M. Floyd, "Applying multi-resolution stochastic modeling to individual tennis points," Tesis de Maestría, Rochester Institute of Technology, 2017. [Online]. Available: https://repository.rit.edu/theses/9474

[15] Z. Liu, K. Jiang, Z. Hou, Y. Lin, and J. S. Dong, "Insight analysis for tennis strategy and tactics," in *2023 IEEE International Conference on Data Mining (ICDM)*. IEEE, 2023, pp. 1169–1174.

[16] S. A. Kovalchik, "Searching for the goat of tennis win prediction," *Journal of Quantitative Analysis in Sports*, vol. 12, no. 3, pp. 127–138, 2016.

[17] R. Bai, K. H. Chong, H. Li, and J. Y. Teh, "Forecasting tennis player matches based on machine learning," in *Machine Learning and Intelligent Computing*, ser. Proceedings of Machine Learning Research, vol. 245. PMLR, 2024, pp. 393–403.

[18] K. Poudel, L.-S. Schmidt, C. N. Jones, S. Baral, T. Nhan, S. Wagle, and J. Vargas, "A unified benchmark of machine learning and deep neural networks for tennis match prediction," *Analytics*, vol. 5, no. 3, p. 22, 2026.

[19] M. Illum, H. C. B. Mikkelsen, and E. Hovad, "Analysis of points outcome in atp grand slam tennis using big data and machine learning," *arXiv preprint arXiv:2506.05866*, 2025.

[20] J. Sackmann, "The Match Charting Project," Repositorio de GitHub, 2026, base de datos de estadística avanzada de tenis. Accedido en 2026. [Online]. Available: https://github.com/JeffSackmann/tennis_MatchChartingProject

[21] D. E. Knuth and R. W. Moore, "An analysis of alpha-beta pruning," *Artificial intelligence*, vol. 6, no. 4, pp. 293–326, 1975.

[22] Y. Nasu, "Efficiently updatable neural-network-based evaluation functions for computer shogi," Documento técnico, 2018. [Online]. Available: https://github.com/ynasu87/nnue/blob/master/docs/nnue.pdf

[23] D. K. Klein, "Neural networks for chess," *ArXiv*, vol. abs/2209.01506, 2022. [Online]. Available: https://api.semanticscholar.org/CorpusID:252089391

[24] Stockfish Development Team, "Stockfish 12: Introducing NNUE evaluation," https://stockfishchess.org/blog/2020/stockfish-12/, 2020, anuncio oficial de integración de redes NNUE en Stockfish.

[25] D. Hooper and K. Whyld, *The Oxford Companion to Chess*, 2nd ed. Oxford: Oxford University Press, 1992.

[26] L. Breiman, J. Friedman, R. A. Olshen, and C. J. Stone, *Classification and Regression Trees*. Belmont, CA: Wadsworth International Group, 1984.

[27] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.

[28] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on tabular data?" *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 507–520, 2022.

[29] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.

[30] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 4, pp. 1–21, 2012.

[31] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

[32] J. A. Hanley and B. J. McNeil, "The meaning and use of the area under a receiver operating characteristic (ROC) curve," *Radiology*, vol. 143, no. 1, pp. 29–36, 1982.

[33] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 70. PMLR, 2017, pp. 1321–1330.

[34] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.

[35] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.