Estimación de la probabilidad condicional de ganar un punto en tenis profesional

Federico Soler

***Resumen*—Analizar un encuentro competitivo permite examinar cómo las decisiones de los jugadores modifican su desarrollo. En ajedrez, las evaluaciones de un motor pueden representarse mediante una barra que indica la ventaja posicional estimada y se actualiza después de cada movimiento. Este trabajo propone la probabilidad condicional de ganar el punto como medida del balance entre ambos jugadores después de cada tiro.**

Para ello, se entrena un modelo XGBoost sobre registros del Match Charting Project, utilizando el tiro actual y los dos anteriores $(t, t-1, t-2)$. El modelo alcanzó un Accuracy del 61.68 %, un AUC-ROC de 0.6578, un Brier Score de 0.2244, un Expected Calibration Error de 0.60 % y F_1-scores de 69.77 % para el sacador y 47.67 % para el restador. Los resultados muestran que la ventana tripartita contiene información predictiva sobre el desenlace del punto, lo que permite construir una representación de la ventaja estimada del sacador sin recurrir al marcador ni a la identidad de los jugadores.

I. Introducción

El motor de ajedrez Stockfish utiliza una arquitectura neuronal NNUE (Efficiently Updatable Neural Network) entrenada para aproximar una función de evaluación clásica (Handcrafted Evaluation, HCE) que se apoyaba en la posición y actividad de las piezas para valorar numéricamente posiciones del tablero. Luego genera y valora continuaciones a partir de la posición actual dando como resultado un puntaje escalar final que se usa como herramienta de análisis para comparar posiciones sucesivas [1].

En ajedrez, las reglas determinan el conjunto finito de movimientos legales a partir de una posición y, para cada movimiento, la posición siguiente queda determinada de forma exacta. Mover un alfil a un cierto casillero desde una posición actual termina inequívocamente en una única posición siguiente [2].

El dataset Match Charting Project (MCP) utilizado en este proyecto registra descripciones de los golpes, pero no sus velocidades ni las posiciones de los jugadores y la pelota [3]. Se acepta como limitación que la representación categórica de los golpes, como una derecha paralela profunda, simplifica en cierta medida la diversidad real de los golpes [4]. Por esta razón, si bien este trabajo busca evaluar cada estado del peloteo, no pretende hacerlo a través de la búsqueda generativa.

En tenis, distintos trabajos han buscado evaluar estrategias de juego [5], [6], pronosticar al ganador del partido [7] o clasificar las terminaciones de los puntos [8], e incluso diseñar métricas de valoración del intercambio [9], [10], [11], [12]. Estas últimas métricas no equivalen directamente a una probabilidad de ganar el punto.

Se eligió como modelo a XGBoost [13], que combina árboles de decisión [14] mediante *gradient boosting* [15] dada su competitividad en tareas tabulares [16] frente a redes profundas [17]. La salida del modelo se transforma de escala logit a probabilidad [18].

Los datos se separan por partido para evitar que observaciones de un mismo encuentro aparezcan tanto en entrenamiento como en prueba [19]. La evaluación considera las métricas Accuracy, Precision, Recall y F1 [20], AUC-ROC [21], Brier Score [22] y Expected Calibration Error [23], [24].

Este trabajo propone entonces la valoración a una granularidad tiro a tiro mediante la estimación después de cada golpe de la probabilidad de victoria del sacador con un modelo XGBoost entrenado a partir del tiro actual y de los dos anteriores, excluyendo deliberadamente features estáticos como el marcador, el ranking y la identidad de los jugadores. La métrica propuesta para la valoración de un estado se define como la probabilidad condicional de que el sacador gane el punto:

$$V(S_t) = P(Y = 1 \mid S_t), \tag{1}$$

donde $Y = 1$ representa la victoria del sacador y S_t sintetiza las características observables del tiro actual y de los dos anteriores. El funcionamiento del modelo se ilustra mediante el análisis de un punto de la final del US Open 2009 entre Roger Federer y Juan Martín del Potro.

El artículo se organiza de modo que la Sección II presenta los antecedentes, la Sección III aborda el marco teórico, la Sección IV detalla la ingeniería de características y el entrenamiento del modelo, la Sección V expone los resultados, el caso de estudio y su discusión, la Sección VI propone trabajos futuros y la Sección VII presenta la conclusión.

II. Antecedentes

Entre los antecedentes que se apoyan en el análisis notacional para estudiar el juego, O'Donoghue e Ingram [6] utilizaron métodos estadísticos descriptivos para identificar diferencias en características de los intercambios, como la duración de los peloteos, sin recurrir al aprendizaje supervisado ni intentar predecir el desenlace de los puntos.

Respecto a posibles continuaciones del juego, Liu et al. [5] utilizaron procesos de decisión de Markov para simular partidos de tenis y evaluar distintas estrategias a partir de probabilidades de transición obtenidas de datos históricos. Sin embargo, estas transiciones son probabilísticas y no permiten determinar exactamente el estado físico resultante de cada acción.

A una granularidad de partido, Kovalchik [7] comparó distintos métodos de predicción de resultados y encontró que los enfoques basados en ranking y Elo eran los más competitivos, aunque presentaban mayores dificultades para

predecir resultados entre jugadores de menor ranking. Más recientemente, Poudel et al. [17] compararon modelos clásicos y redes profundas para predecir al ganador de partidos de tenis, estudiando las diferencias de desempeño entre ambos enfoques.

En cuanto a medidas de ventaja, Carvalho et al. [9] formalizaron el Índice de Ventaja Posicional (Positional Advantage Index, PA Index) a partir de las posiciones relativas de los jugadores, encontrando que permitía identificar cambios en su coordinación espacial durante los peloteos. Posteriormente, van Meurs et al. [10] evaluaron distintas modificaciones del índice utilizando datos de Hawk-Eye y concluyeron que la fórmula original seguía siendo una medida sólida de ventaja posicional entre las variantes estudiadas.

Sobre la probabilidad de ganar el punto, Kovalchik y Reid [4] utilizaron datos de seguimiento y técnicas de agrupamiento no supervisado para clasificar los golpes, analizando la asociación de cada categoría con la probabilidad de victoria, encontrando que los tiros más rápidos y con menor altura sobre la red tendían a ser los más efectivos.

Para la valoración de tiros individuales, Floyd et al. [11] formularon el Expected Shot Value (ESV) a partir de modelos de valor de posesión del baloncesto, dividiendo la cancha en 30 zonas y utilizando categorías de tiros y matrices de transición para calcular un valor esperado después de cada golpe. Posteriormente, Emery [12] amplió este enfoque incorporando información sobre el tipo de golpe, su velocidad y efecto, logrando mejorar la correlación entre el ESV y la frecuencia de puntos ganados, aunque reconoció que los puntajes asignados a las categorías seguían siendo arbitrarios y que el modelo no capturaba adecuadamente ciertas ventajas generadas por el saque.

Sobre el uso de XGBoost en tenis, Mlakar y Kovalchik [8] utilizaron datos de seguimiento del Australian Open 2017 para estudiar la presión temporal mediante el tiempo transcurrido entre el impacto y el cruce de la pelota sobre la red. A partir de características de esa secuencia, entrenaron modelos para clasificar si el punto terminaba mediante un tiro ganador o un error, superando a un clasificador que siempre predecía la categoría mayoritaria. Aunque su objetivo difiere de estimar la probabilidad de victoria del sacador, constituye un antecedente del uso de características dinámicas del intercambio para realizar predicciones.

III. Marco teórico

III-A. Arquitectura del modelo

Los ensambles de árboles han mostrado un rendimiento competitivo frente a redes profundas en tareas tabulares según la literatura consultada [16], [17].

Un árbol de clasificación divide el conjunto de datos en subgrupos, seleccionando en cada nodo un punto de corte sobre una variable que permita reducir la impureza de las clases hasta alcanzar un criterio de detención, como una profundidad máxima predeterminada. Las observaciones nuevas recorren las divisiones del árbol hasta llegar a una hoja, donde reciben la predicción de la clase mayoritaria en ella [14].

El principio de *Gradient Boosting* construye una secuencia de árboles que colaboran entre sí. A partir de una predicción inicial, cada árbol se entrena para corregir el error del ensamble construido hasta ese momento, siguiendo la dirección que reduce la función de pérdida [15].

La arquitectura XGBoost (Extreme Gradient Boosting) es una implementación optimizada del *boosting* tradicional que regulariza la complejidad del ensamble y reduce la magnitud de las contribuciones de los árboles mediante una tasa de aprendizaje para combatir el sobreajuste. Durante el entrenamiento, XGBoost selecciona divisiones de las observaciones que permiten reducir la función de pérdida, comparándolas con otras divisiones candidatas. Al evaluar una observación nueva, esta recorre las ramas de cada árbol hasta llegar a una hoja que contiene un peso aprendido durante el entrenamiento, denominado *leaf weight*. Este peso modifica el margen logit de la predicción, aumentándolo si es positivo o reduciéndolo si es negativo. Para comenzar esta suma, el ensamble necesita una predicción inicial, que puede estimarse a partir de las etiquetas de entrenamiento, antes de incorporar las contribuciones de los árboles. Una vez sumadas todas estas contribuciones al sesgo base, el resultado todavía se encuentra en escala logit y no puede interpretarse directamente como una probabilidad [13].

Para convertirlo en la probabilidad de que $Y = 1$, se utiliza la función sigmoide: $p = 1/(1 + e^{-z})$, donde z representa el margen logit final obtenido por el ensamble. La escala logit es una forma alternativa de expresar una probabilidad, utilizando números que pueden ir desde menos infinito hasta más infinito, en lugar del intervalo entre 0 y 1. El logit se calcula mediante $z = \ln(p/(1-p))$. Un logit de 0 equivale a una probabilidad del $50\,\%$. Los valores positivos representan probabilidades superiores al $50\,\%$ y los negativos, inferiores [18].

III-B. Métricas de evaluación

Accuracy calcula la proporción de aciertos del modelo, es decir, verdaderos positivos (VP) y verdaderos negativos (VN) sobre el total de predicciones. Por ejemplo, si el modelo realiza 100 predicciones y obtiene 40 VP y 20 VN, su Accuracy es del $60\,\%$. Precision mide qué proporción de las victorias predichas del sacador ($\hat{Y} = 1$) corresponde a victorias reales ($Y = 1$), mientras que Recall mide qué proporción de las victorias reales del sacador ($Y = 1$) fue correctamente identificada ($\hat{Y} = 1$). F1-score penaliza los desequilibrios entre Precision y Recall, de manera que un valor bajo en cualquiera de las dos reduce el resultado conjunto [20].

Dado que las métricas previamente mencionadas trabajan colapsando la probabilidad asignada según un umbral ($p = 0{,}5$) para poder diferenciar aciertos de errores, se incluye el Brier Score, que relaciona la etiqueta final (Y) directamente con la probabilidad asignada por el modelo (p). Por ejemplo, si el modelo predice un $80\,\%$ (0,80) y el sacador termina ganando el punto (1), el error puntual de ese tiro es muy bajo, $(0{,}80 - 1)^2 = 0{,}04$. En cambio, si pierde el punto (0), el error castiga la sobreconfianza, $(0{,}80 - 0)^2 = 0{,}64$. Al promediar estos errores sobre cientos de miles de tiros, se obtiene un indicador global donde un puntaje más bajo refleja un menor error probabilístico [22].

La métrica ROC-AUC mide la frecuencia con que se asigna una mayor probabilidad a un tiro que termina en victoria ($Y =$

1) que a uno que termina en derrota ($Y = 0$). Por ejemplo, un ROC-AUC de 0,65 significa que, al elegir aleatoriamente un golpe perteneciente a un punto ganado ($Y = 1$) y otro perteneciente a un punto perdido ($Y = 0$), el modelo ordena correctamente el par aproximadamente el 65 % de las veces [21].

El Expected Calibration Error (ECE) particiona el espacio de predicciones en intervalos (*bins*) según sus probabilidades. En cada grupo se calcula el promedio de las probabilidades de victoria del sacador (confianza media) y el porcentaje de tiros que pertenecen a puntos ganados por el sacador (frecuencia observada). La diferencia absoluta entre ambos se multiplica por la proporción de observaciones que contiene respecto del total. Finalmente, se suman los errores de todos los grupos, teniendo en cuenta cuántas observaciones contiene cada uno, para obtener el ECE [23]. Sin embargo, el valor obtenido debe interpretarse como una estimación del error de calibración dado que la métrica se calcula utilizando los tiros disponibles en el conjunto de prueba, por lo que evaluar el mismo modelo con nuevos partidos podría producir un ECE diferente [24].

IV. Componentes

IV-A. Ingeniería de características

Del corpus completo del MCP se descartaron los encuentros del circuito femenino (WTA) para centrar el análisis exclusivamente en partidos entre jugadores diestros del circuito profesional masculino (ATP) con el objetivo de filtrar posibles patrones tácticos presentes en uno de los circuitos pero no en el otro y evitar diferencias tácticas por lateralidad. Se depuraron también jugadas atípicas (como desvíos fortuitos por contacto con la faja de la red) y registros truncos carentes de secuencia válida de intercambio.

Durante las primeras versiones del prototipo se observó que variables estáticas ajenas al peloteo como el ranking, la identidad de los jugadores, la superficie, el torneo y el marcador encabezaban sistemáticamente los gráficos de análisis de feature importance, aportando información predictiva sin describir las acciones ejecutadas durante el intercambio. Se entiende por variable estática aquella cuyo valor permanece constante durante los sucesivos tiros de un punto, aunque pueda cambiar entre puntos o partidos. Su predominio motivó la decisión de excluir deliberadamente estas variables para concentrar el aprendizaje en características dinámicas del peloteo, como el tipo de golpe, su dirección y profundidad.

La identidad de los jugadores también fue excluida para evitar que el modelo utilizara su historial competitivo como atajo predictivo. Por ejemplo, reconocer a Federer, Nadal o Djokovic podría llevarlo a asignar probabilidades favorables basándose en sus resultados históricos, sin distinguir suficientemente las características del golpe ejecutado. Además, al no depender de identidades conocidas durante el entrenamiento, la representación puede aplicarse a jugadores que ingresen posteriormente al circuito sin requerir nuevas variables para identificarlos.

La representación final se estructura en 94 características, principalmente binarias (*One-Hot*), que describen una ventana tripartita: el tiro actual (t), la respuesta previa del adversario ($t-1$) y el impacto preparatorio propio ($t-2$). Para cada tiro se utilizan indicadores de tipo de golpe, dirección, profundidad y subida a la red. Son 31 variables para cada uno de los dos tiros anteriores y 30 para el tiro actual, que suman 92 para la ventana completa. Se agrega `sacador_al_tiro`, que identifica al ejecutor del impacto actual (1 para el sacador, 0 para el restador) y permite interpretar las características del golpe desde la perspectiva del sacador, además de `indice_tiro`, que registra la posición del tiro dentro del punto.

IV-B. Entrenamiento del modelo

El proceso se desarrolló en el ecosistema científico de Python, empleando NumPy, Pandas, Scikit-Learn y la librería XGBoost sobre Google Colab.

Una vez construidas las ventanas de tres tiros, los datos se dividieron en entrenamiento (80 %) y prueba (20 %) cuidando que todos los registros de un mismo partido quedaran en el mismo conjunto. Si algunos tiros de un partido se utilizaran para entrenar y otros del mismo partido para evaluar, el modelo estaría siendo probado con información de encuentros que ya había visto durante el entrenamiento, lo que podría producir una fuga de información.

En pruebas con 350 árboles se observó que la función de pérdida alcanzaba una meseta a partir de los 200 árboles. Extender el ensamble aportaba una ganancia marginal inferior a $+0{,}05\,\%$ en AUC-ROC, duplicando el costo computacional. Una profundidad de 6 niveles por árbol produjo resultados menos favorables al modelar las interacciones entre los tres turnos del intercambio. A su vez, al permitir profundidades de 10 o 12 niveles, los árboles tendían a memorizar ruido de las anotaciones del MCP, degradando el Brier Score y el ECE.

Al utilizar la totalidad de las características, las variables dominantes del tenis (como la dirección del saque o los impactos ganadores en la red) eran seleccionadas sistemáticamente en los nodos raíz de casi todos los árboles, generando estimadores altamente correlacionados y desatendiendo variables tácticas secundarias. Forzar a cada árbol a prescindir aleatoriamente de un $20\,\%$ de las columnas obligó al algoritmo a explorar variables alternativas, descorrelacionando los árboles y enriqueciendo la diversidad del ensamble. A su vez, entrenar cada árbol con el $90\,\%$ aleatorio de los tiros favoreció que jugadas de baja frecuencia muestral (como *drop-shots*) ganaran soporte estadístico en los árboles individuales para preservar la representatividad de los impactos poco frecuentes.

V. Análisis y resultados

V-A. Evaluación del modelo

El Cuadro I muestra el desempeño predictivo del ensamble propuesto frente a dos modelos *dummy* y a las sucesivas ventanas de memoria temporal sobre el conjunto de prueba. Un modelo *dummy* es un clasificador de referencia que prescinde de las características de entrada. En este trabajo se evalúan dos variantes.

Dummy Uniforme asigna a todos los tiros una probabilidad fija de victoria del sacador de $50\,\%$ y genera las clases predichas mediante elecciones aleatorias equiprobables entre sacador y restador. En el conjunto de prueba obtuvo un

Cuadro I
ESTUDIO DE ABLACIÓN TEMPORAL DEL ENSAMBLE SUPERVISADO FRENTE A LÍNEAS BASE *Dummy*

Modelo	**Accuracy**	**AUC-ROC**	**Brier Score**	**ECE**	**Sacador (Clase 1)**			**Restador (Clase 0)**		
					Prec.	**Rec.**	F_1	**Prec.**	**Rec.**	F_1
Dummy Uniforme	50.01 %	50.00 %	0.2500	7.18 %	57.19 %	50.02 %	53.37 %	42.83 %	49.99 %	46.13 %
Dummy Mayoría	57.18 %	50.00 %	0.2448	0.18 %	57.18 %	100.00 %	72.76 %	0.00 %	0.00 %	0.00 %
XGBoost (t)	60.87 %	64.23 %	0.2288	0.31 %	62.84 %	77.23 %	69.30 %	56.20 %	39.02 %	46.06 %
XGBoost $(t, t-1)$	61.58 %	65.62 %	0.2248	0.50 %	63.47 %	77.30 %	69.70 %	57.24 %	40.59 %	47.50 %
XGBoost $(t, t-1, t-2)$	61.68 %	65.78 %	0.2244	0.60 %	63.55 %	77.35 %	69.77 %	57.40 %	40.76 %	47.67 %

Cuadro II
MATRIZ DE CONFUSIÓN SOBRE EL CONJUNTO DE PRUEBA

	Predicción del Modelo ($\hat{Y}$)		
Clase Real (Y)	**Restador ($\hat{Y}=0$, Negativo)**	**Sacador ($\hat{Y}=1$, Positivo)**	**Total Observado**
Restador ($Y=0$, Negativo)	126.071 (17.45 %) **Verdadero Negativo (VN / Negativo correcto)** Restador gana y el modelo predice restador	183.204 (25.36 %) **Falso Positivo (FP / Error Tipo I)** Restador gana pero el modelo predice sacador	309.275 (42.82 %)
Sacador ($Y=1$, Positivo)	93.566 (12.95 %) **Falso Negativo (FN / Error Tipo II)** Sacador gana pero el modelo predice restador	319.439 (44.23 %) **Verdadero Positivo (VP / Positivo correcto)** Sacador gana y el modelo predice sacador	413.005 (57.18 %)
Total Asignado	219.637 (30.41 %)	502.643 (69.59 %)	722.280 (100.0 %)

Accuracy observado de $50{,}01\,\%$, cercano al $50\,\%$ esperado. Su AUC-ROC es $50{,}00\,\%$, su Brier Score es $0{,}2500$ y su ECE es $7{,}18\,\%$, dado que las probabilidades utilizadas para evaluar estas métricas permanecen constantes en $0{,}50$, aunque las clases predichas sean aleatorias.

Dummy Mayoría utiliza la proporción de victorias del sacador en el conjunto de entrenamiento como probabilidad fija y predice siempre la clase sacador. Obtiene un Accuracy de $57{,}18\,\%$ y carece de capacidad discriminativa (AUC-ROC $= 50{,}00\,\%$). Su ECE es $0{,}18\,\%$ porque la prevalencia de entrenamiento es cercana a la observada en prueba.

El estudio de ablación temporal muestra que incorporar el tiro anterior $(t-1)$ produce una mejora de 1.39 puntos porcentuales en AUC-ROC, mientras que incorporar un tiro más $(t-2)$ aporta una mejora adicional de 0.16 puntos porcentuales.

El modelo final propuesto alcanzó un Accuracy global del 61.68 %, un AUC-ROC de 0.6578, un Brier Score de 0.2244 y un ECE de 0.60 %.

Sobre los 722.280 registros del conjunto de prueba, el clasificador identificó correctamente 319.439 victorias del sacador (Verdaderos Positivos, VP) y 126.071 victorias del restador (Verdaderos Negativos, VN). Los errores se distribuyeron en 183.204 predicciones favorables al sacador cuando ganó el restador (Falsos Positivos, FP) y 93.566 predicciones favorables al restador cuando ganó el sacador (Falsos Negativos, FN). Los 445.510 aciertos explican el Accuracy global del 61.68 %. El modelo alcanzó un F_1 de 69.77 % para el sacador y de 47.67 % para el restador (Cuadro II).

V-B. Caso de estudio

Para ilustrar la interpretabilidad del modelo, se evaluó el primer punto del segundo game de la final del US Open 2009 (Del Potro al servicio frente a Federer). Se utilizaron los códigos de los golpes tal como aparecen en el registro, sin reconstruir manualmente las profundidades no anotadas.

La Figura 1 exhibe la evolución de las probabilidades condicionales de victoria estimadas por el modelo tiro a tiro para ambos jugadores, desde el segundo saque hasta la última volea. Para esta última, el modelo estima una probabilidad de victoria de $60{,}8\,\%$ para Federer y de $39{,}2\,\%$ para Del Potro.

Cuadro III
CÁLCULO DEL VALOR DEL TIRO 4 MEDIANTE XGBOOST

Árbol 1		
Decisión	**Feature**	**Valor**
1	`indice_tiro`	2
2	`indice_tiro`	2
3	`prev_subida_a_red`	0
4	`prev_profundidad_9`	1
5	`sacador_al_tiro`	1
6	`profundidad_-`	1
7	`direccion_-`	0
8	`prev_golpe_s`	1
Predicción del Ensamble		
Componente	**Expresión**	**Aporte**
Sesgo base	$b_0 = \ln(p_0/(1-p_0))$	$+0{,}282034$
Árbol 1	$f_1(x)$ (*leaf weight*)	$-0{,}007154$
200 árboles	$\sum_{m=1}^{200} f_m(\mathbf{x})$	$-0{,}121313$
Logit final	$z = b_0 + \sum_{m=1}^{200} f_m(\mathbf{x})$	$+0{,}160721$
Probabilidad final	$\sigma(z) = 1/(1+e^{-z})$	54,01 %

El cuarto tiro del punto corresponde a una derecha registrada con el código `f3`, ejecutada por el sacador (Juan Martín del Potro). Para evaluarla, XGBoost recibe como entrada el vector de 94 características, principalmente *One-Hot*, que la describe. Al ingresar al primero de los 200 árboles, el tiro comienza en el nodo raíz, que pregunta por el índice del

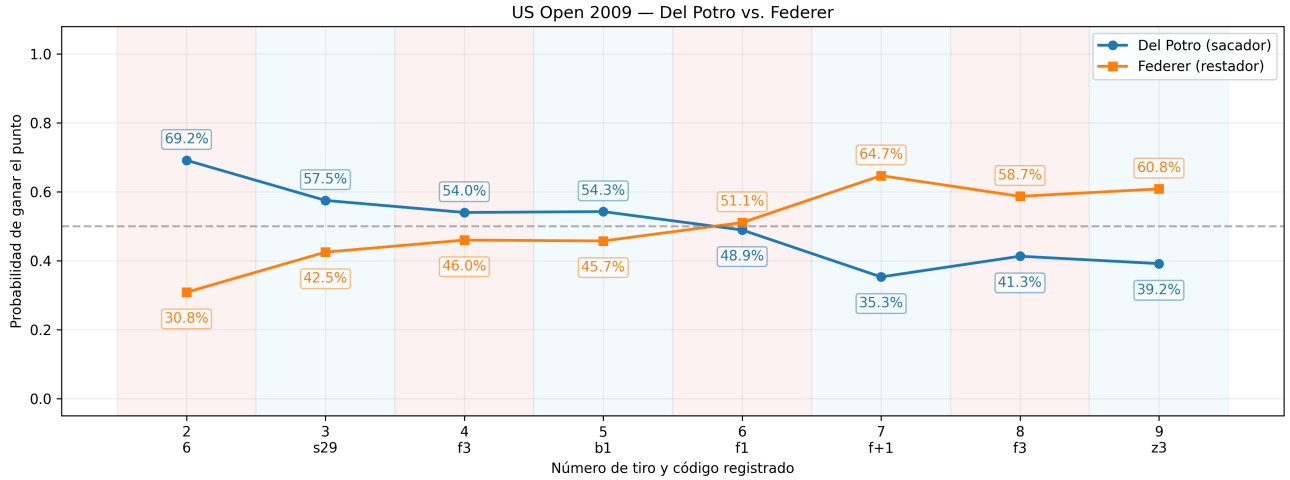


Figura 1. Evolución de la probabilidad condicional de victoria para el caso de estudio. Los códigos de los tiros representan: 6 (segundo saque a la T), s29 (slice de revés al centro y profundo), f3 (derecha hacia el lado del revés del rival), b1 (revés hacia el lado de la derecha del rival), f1 (derecha hacia el lado de la derecha del rival), f+1 (derecha con subida a la red hacia el lado de la derecha del rival) y z3 (volea de revés hacia el lado del revés del rival). Los números 1, 2 y 3 indican la dirección del golpe; 7, 8 y 9 indican profundidad corta, media y profunda, respectivamente; y el símbolo + indica subida a la red. Federer (F) gana el punto con su volea de revés cruzada corta ganadora. DP corresponde a Del Potro.

tiro (`indice_tiro`). En el tiro 4 vale 2, porque el índice comienza en 0 para el segundo servicio (tiro 2), por lo que el tiro continúa por la rama del árbol correspondiente hasta atravesar otros siete nodos y llegar a una hoja que contiene un *leaf weight* de $-0{,}007154$.

XGBoost suma ese peso al margen inicial en escala logit, obtenido al transformar el sesgo base de $0{,}570045$, situando el margen tras este primer paso en $+0{,}274880$, y se avanza sucesivamente a través de los siguientes árboles. Al atravesar los 200 árboles, la corrección conjunta de todos los estimadores asciende a $-0{,}121313$, alcanzando un logit final de $+0{,}160721$ que luego de pasar por la función sigmoide devuelve finalmente $\approx 0{,}5401$, es decir, un $54{,}01\,\%$ de probabilidad de victoria para el sacador. El cálculo detallado se resume en el Cuadro III.

V-C. Discusión

Los resultados del estudio de ablación temporal muestran que incorporar información de los tiros anteriores mejora la capacidad predictiva del modelo, aunque la ganancia disminuye al ampliar la ventana. Este comportamiento llevó a adoptar una ventana de segundo orden ($k = 2$) como un compromiso entre capacidad predictiva y dimensionalidad dadas las configuraciones evaluadas.

El modelo XGBoost supera a las dos líneas base en AUC-ROC y Brier Score, produciendo probabilidades variables según las características de los tiros. Sin embargo, su desempeño es desigual entre las clases, con mayores dificultades para identificar los puntos ganados por el restador. Asimismo, el ECE obtenido indica una buena calibración global en el conjunto de prueba, aunque esto no implica que el modelo pueda anticipar con certeza el desenlace de cada punto.

El caso de estudio permite analizar el desarrollo del punto, aunque sus estimaciones no demuestran que cada golpe haya sido la mejor decisión disponible. La primera inversión de ventaja donde el restador pasa a tener mayor probabilidad de ganar el punto ocurre luego del tiro 6 de Del Potro. La toma de la red (tiro 7), un movimiento ofensivo de Federer, ocurre a continuación. Los tiros 8 y 9 mantienen la valoración a favor del restador.

VI. Trabajos futuros

En trabajos futuros, se podría incorporar información de seguimiento óptico continuo para describir la cinemática tridimensional de la pelota y los competidores. Una de las principales limitaciones es la ausencia de variables cinemáticas continuas como la velocidad, la trayectoria o la posición de los jugadores, por lo que múltiples ejecuciones físicamente diferentes quedan representadas bajo una misma categoría notacional.

Se sugiere también explorar ventanas completas que abarquen todos los golpes previos de la secuencia del punto, más allá de la ventana tripartita aquí explorada. Esto permitiría evaluar si acciones anteriores a los últimos tres tiros aportan información relevante para valorar el estado actual del peloteo. Por ejemplo, una sucesión de golpes podría desplazar progresivamente al rival o preparar una subida a la red que no se comprende completamente observando sólo los impactos más recientes.

Otra línea de trabajo sería evaluar la utilidad de la visualización junto con entrenadores y jugadores. Se podría analizar si las variaciones de probabilidad ayudan a identificar momentos relevantes del intercambio y si estos coinciden con la valoración de los especialistas sobre cómo se construyen las oportunidades antes del golpe final. Las discrepancias entre la interpretación de los especialistas y la valoración del modelo permitirían detectar y estudiar posibles limitaciones, tanto de las características registradas como de las estimaciones obtenidas.

VII. Conclusión

Este trabajo muestra que es posible utilizar la estimación de la probabilidad condicional de victoria del sacador tras cada golpe como una valoración del estado del peloteo, donde un aumento representa una situación más favorable para el sacador.

Los resultados obtenidos muestran que el modelo logra capturar suficiente señal predictiva mediante la ventana temporal propuesta, aunque las probabilidades estimadas, si bien presentan una buena calibración global en el conjunto de prueba, no permiten anticipar con certeza el desenlace del punto.

El principal aporte metodológico de este trabajo reside en la ingeniería de características aplicada, que combina la exclusión de la identidad de los jugadores, el filtrado de variables contextuales estáticas y la ventana temporal tripartita $(t, t-1, t-2)$, aunque la representación categórica disponible limita la posibilidad de distinguir ejecuciones físicamente diferentes.

Referencias

[1] S. Maharaj, N. Polson, and A. Turk, "Chess AI: competing paradigms for machine intelligence," *Entropy*, vol. 24, no. 4, p. 550, 2022, doi: 10.3390/e24040550.

[2] D. Hooper and K. Whyld, *The Oxford Companion to Chess*, 2nd ed. Oxford: Oxford University Press, 1992.

[3] S. Kovalchik, "Why tennis is still not ready to play moneyball," *Harvard Data Science Review*, vol. 3, no. 1, 2021, doi: 10.1162/99608f92.b665c0f4.

[4] S. Kovalchik and M. Reid, "A shot taxonomy in the era of tracking data in professional tennis," *Journal of Sports Sciences*, vol. 36, no. 18, pp. 2096–2104, 2018, doi: 10.1080/02640414.2018.1438094.

[5] Z. Liu, K. Jiang, Z. Hou, Y. Lin, and J. S. Dong, "Insight analysis for tennis strategy and tactics," in *2023 IEEE International Conference on Data Mining (ICDM)*. IEEE, 2023, pp. 1169–1174, doi: 10.1109/ICDM58522.2023.00143.

[6] P. O'Donoghue and B. Ingram, "A notational analysis of elite tennis strategy," *Journal of Sports Sciences*, vol. 19, no. 2, pp. 107–115, 2001, doi: 10.1080/026404101300036299.

[7] S. A. Kovalchik, "Searching for the GOAT of tennis win prediction," *Journal of Quantitative Analysis in Sports*, vol. 12, no. 3, pp. 127–138, 2016, doi: 10.1515/jqas-2015-0059.

[8] M. Mlakar and S. A. Kovalchik, "Analysing time pressure in professional tennis," *Journal of Sports Analytics*, vol. 6, no. 2, pp. 147–154, 2020, doi: 10.3233/JSA-200406.

[9] J. Carvalho, D. Araújo, B. Travassos, P. Esteves, L. Pessanha, F. Pereira, and K. Davids, "Dynamics of players' relative positioning during baseline rallies in tennis," *Journal of Sports Sciences*, vol. 31, no. 14, pp. 1596–1605, 2013, doi: 10.1080/02640414.2013.792944.

[10] E. van Meurs, T. Buszard, S. Kovalchik, D. Farrow, and M. Reid, "Interpersonal coordination in tennis: assessing the positional advantage index with australian open hawkeye data," *International Journal of Performance Analysis in Sport*, vol. 21, no. 1, pp. 22–32, 2021, doi: 10.1080/24748668.2020.1843213.

[11] C. M. Floyd, M. Hoffman, and E. Fokoue, "Shot-by-shot stochastic modeling of individual tennis points," *Journal of Quantitative Analysis in Sports*, vol. 16, no. 1, pp. 57–71, 2020, doi: 10.1515/jqas-2018-0036.

[12] C. Emery, "Augmenting tennis point stochastic modeling utilizing spatiotemporal shot data," Senior Honors Thesis, Carnegie Mellon University, 2020, director: Peter Freeman. [Online]. Available: https://coreyemery.com/files/ce_thesis_paper.pdf

[13] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ser. KDD '16. New York, NY, USA: Association for Computing Machinery, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[14] W.-Y. Loh, "Classification and regression trees," *WIREs Data Mining and Knowledge Discovery*, vol. 1, no. 1, pp. 14–23, 2011, doi: 10.1002/widm.8.

[15] J. H. Friedman, "Greedy function approximation: a gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001, doi: 10.1214/aos/1013203451.

[16] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?" *Advances in Neural Information Processing Systems*, vol. 35, pp. 507–520, 2022, doi: 10.52202/068431-0037.

[17] K. Poudel, L.-S. Schmidt, C. N. Jones, S. Baral, T. Nhan, S. Wagle, and J. Vargas, "A unified benchmark of machine learning and deep neural networks for tennis match prediction," *Analytics*, vol. 5, no. 3, 2026, art. 22. doi: 10.3390/analytics5030022.

[18] S. Sperandei, "Understanding logistic regression analysis," *Biochemia Medica*, vol. 24, no. 1, pp. 12–18, 2014, doi: 10.11613/BM.2014.003.

[19] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 4, pp. 1–21, 2012, doi: 10.1145/2382577.2382579.

[20] C. Ferri, J. Hernández-Orallo, and R. Modroiu, "An experimental comparison of performance measures for classification," *Pattern Recognition Letters*, vol. 30, no. 1, pp. 27–38, 2009, doi: 10.1016/j.patrec.2008.08.010.

[21] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006, ROC Analysis in Pattern Recognition. doi: 10.1016/j.patrec.2005.10.010.

[22] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950, doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

[23] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70. PMLR, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[24] R. Roelofs, N. Cain, J. Shlens, and M. C. Mozer, "Mitigating bias in calibration error estimation," in *Proceedings of The 25th International Conference on Artificial Intelligence and Statistics*, ser. Proceedings of Machine Learning Research, G. Camps-Valls, F. J. R. Ruiz, and I. Valera, Eds., vol. 151. PMLR, 28–30 Mar 2022, pp. 4036–4054. [Online]. Available: https://proceedings.mlr.press/v151/roelofs22a.html